

基于 Transformer 的锂电池早期循环寿命预测 与可解释性分析

数据来源: Severson et al., *Nature Energy*, 2019

2026 年 9 月 14 日

摘要

快充策略对锂离子电池循环寿命的影响机制是电池管理系统优化的核心问题。本文基于 MIT-Stanford 124 颗 A123 LFP 18650 电池的快充老化数据集, 构建统计分析—机器学习预测—可解释性验证的完整研究闭环, 任务定义为早期循环寿命预测 (用前 100 个循环预测总寿命)。在统计层面, 采用 Spearman 秩相关、分层交互分析 (Fisher r-to-z 检验) 与 Benjamini-Hochberg FDR 校正, 量化充电策略参数 (C1、Q1、C2) 及各 SOC 区间倍率暴露对循环寿命的主效应与交互效应, 发现 Q1 (阶段切换 SOC) 是显著的主效应与交互枢纽变量, C1×Q1 交互经检验显著 ($|\Delta\rho| = 0.824$, $p \approx 5 \times 10^{-7}$)。在预测层面, 采用四层渐进式特征体系与 Transformer 架构, 在公平对比下 (Ridge/RF 与 LSTM/Transformer 输入同一套原始序列) 5 折交叉验证 R^2 达 0.827, 留出测试集 (10 次分层划分) R^2 为 0.726 ± 0.177 。在可解释层面, 对 Transformer 本身采用 Integrated Gradients、置换重要性与注意力 rollout, 并附随机初始化与时间轴打乱基线, IG 归因最强的动态特征是内阻 (IR), SOC 区间倍率与策略参数 (C1/C2) 排名靠前。三层分析共同揭示与数据一致的快充设计方向: 低 SOC 区间集中高倍率充电、高 SOC 区间降倍率、保持两步倍率平滑过渡。

关键词: 锂离子电池; 早期循环寿命预测; 快充策略; Transformer; Spearman 相关; Fisher z 检验; Integrated Gradients

目录

1	引言	4
2	数据集与预处理	4
2.1	数据概述	4
2.2	快充策略结构	4
2.3	数据预处理	5
2.3.1	循环编号修正	5
2.3.2	SOH 计算	5
2.4	整体统计	5
3	长寿与短寿策略对比分析	6
3.1	极端策略识别	6
3.2	关键差异分析	6
4	Spearman 秩相关与 SOC 区间分析	7
4.1	单一参数主效应	7
4.2	不同 SOC 区间的倍率效应	8
4.3	散点图验证	9
5	交互效应	10
5.1	分层 Spearman 交互分析	10
5.2	交互效应的物理含义	10
5.3	主效应与交互效应分列	10
6	基于 Transformer 的寿命预测	11
6.1	问题定义	11
6.2	四层渐进式特征体系	11
6.3	Transformer 模型架构	12
6.4	实验设计	12
6.5	软件环境	13
7	预测结果与分析	13
7.1	模型对比	13
7.2	特征消融实验	13
7.3	留出测试集性能	14
7.4	与已发表基线的定位	16

目录	3
8 可解释性分析	16
8.1 Transformer 可解释性 (Integrated Gradients 与置换重要性)	16
8.2 注意力 rollout 与基线对照	17
9 讨论	18
9.1 研究闭环验证	18
9.2 与数据一致的设计方向	19
9.3 研究局限	19
10 结论	20
A 特征列表	21

1 引言

锂离子电池作为电动汽车和便携式电子设备的核心储能单元，其快充性能与循环寿命之间的权衡是制约技术发展的关键瓶颈。快速充电虽然大幅缩短充电时间，但不当的快充策略可能导致负极析锂、SEI 膜过度生长和电极材料机械退化，从而显著缩短电池使用寿命 [1]。

理解充电策略参数与电池退化之间的定量关系，并建立准确的寿命预测模型，对于优化电池管理系统（BMS）和设计长寿命快充协议具有重要意义。然而，充电策略的影响具有高度非线性和参数间复杂的交互作用，传统的单一变量分析方法难以全面揭示其内在规律。

Severson 等人 [1] 在 Nature Energy 上发表了基于 124 颗 A123 LFP 18650 电池的快充老化实验数据，涵盖 68 种不同的两阶段恒流-恒压（CC-CV）充电策略。该数据集为系统研究快充参数对电池寿命的影响提供了宝贵的基础。

本文基于该数据集，采用**统计分析—机器学习预测—可解释性验证**的三阶段研究框架：

- (1) **统计层面**：运用 Spearman 秩相关分析与分层交互分析，量化充电策略参数及各 SOC 区间倍率暴露量对循环寿命的主效应与交互效应；
- (2) **预测层面**：设计四层渐进式特征体系，基于 Transformer 架构实现循环寿命预测，并与 Ridge 回归、随机森林、LSTM 等基线模型及朴素基线进行系统对比；
- (3) **可解释层面**：综合运用 Integrated Gradients、置换重要性与注意力 rollout，揭示模型预测的决策依据，验证与统计分析的结论一致性。

2 数据集与预处理

2.1 数据概述

本研究使用 MIT-Stanford 电池快充老化数据集 [1]，共包含 124 颗 A123 18650 磷酸铁锂（LFP）电池，额定容量 1.1 Ah，涵盖 68 种快充策略。所有电池经历完整的循环老化测试，直至容量衰减至额定容量的 80%。

2.2 快充策略结构

所有电池采用两阶段 CC-CV 充电协议：

- **阶段一**：以倍率 C_1 恒流充电至 $\text{SOC} = Q_1\%$ ；
- **阶段二**：以倍率 C_2 恒流充电至 $\text{SOC} = 80\%$ ；

- 阶段三：1C CC-CV 充电至满容量，截止电流 $C/50$ （所有电池统一）。

策略参数范围为： $C_1 \in [1.0, 8.0]C$ ， $Q_1 \in [2, 80]\%$ ， $C_2 \in [3.0, 6.0]C$ 。

2.3 数据预处理

2.3.1 循环编号修正

数据集中前 5 颗电池（bat 0-4）因两个实验数据集的拼接导致 `cycle` 列编号重复（以 bat 0 为例：原始编号为 $1 \rightarrow 662 \rightarrow 663 \rightarrow 1189 \rightarrow 1 \rightarrow 662$ ）。本文按行顺序将其重新编号为 $1 \rightarrow 1851$ 。其余 119 颗电池的循环编号无需修正。

2.3.2 SOH 计算

健康状态（State of Health, SOH）基于放电容量与额定容量的比值计算：

$$SOH_i(k) = \frac{Q_{\text{discharge},i}(k)}{1.1 \text{ Ah}} \quad (1)$$

其中 $Q_{\text{discharge},i}(k)$ 为第 i 颗电池第 k 次循环的放电容量。

2.4 整体统计

表1汇总了 124 颗电池的循环寿命与总充电时间分布，图1展示了其箱线分布。

表 1: 循环寿命与充电时间整体统计

指标	最小值	最大值	中位数	均值
循环寿命 (cycles)	148	2237	750	809.2
总充电时间 (h)	2128.1	31438.0	8234.7	9128.3




图 1: 124 颗电池的循环寿命与总充电时间分布

3 长寿与短寿策略对比分析

3.1 极端策略识别

按平均循环寿命排序，表2和表3分别列出寿命最长和最短的 5 种策略。

表 2: 长寿策略 Top 5

策略	C_1 (C)	Q_1 (%)	C_2 (C)	平均寿命	电池数
3.6C(80%)-3.6C	3.6	80	3.6	2083	3
4C(80%)-4C	4.0	80	4.0	1572	2
4.8C(80%)-4.8C-newstructure	4.8	80	4.8	1549	5
5C(67%)-4C-newstructure	5.0	67	4.0	1116	6
5.3C(54%)-4C-newstructure	5.3	54	4.0	1074	8

表 3: 短寿策略 Top 5

策略	C_1 (C)	Q_1 (%)	C_2 (C)	平均寿命	电池数
5.6C(65%)-3C	5.6	65	3.0	429	1
6C(52%)-3.5C	6.0	52	3.5	429	1
2C(7%)-5.5C	2.0	7	5.5	335	1
1C(4%)-6C	1.0	4	6.0	300	1
2C(10%)-6C	2.0	10	6.0	148	1

3.2 关键差异分析

将长寿策略与短寿策略进行逐参数对比，如表4所示。

表 4: 长寿与短寿策略参数对比

参数	长寿策略 (Top 5)	短寿策略 (Top 5)
C_1 范围	3.6C – 5.3C	1.0C – 6.0C
C_1 均值	$\approx 4.5C$	$\approx 3.3C$
Q_1 范围	54% – 80%	4% – 65%
Q_1 均值	$\approx 72\%$	$\approx 28\%$
C_2 范围	3.6C – 4.8C	3.0C – 6.0C
C_2 均值	$\approx 4.1C$	$\approx 4.8C$
$ C_1 - C_2 $	$\approx 0.4C$ (几乎一致)	1.5C – 5.0C (剧烈跳变)

分析表明， Q_1 （阶段切换 SOC）是长寿与短寿策略之间差异最悬殊的参数：长寿策略的 Q_1 均值高达 72%，而短寿策略仅 28%。长寿策略在低 SOC 阶段以适中倍率覆盖了绝大部分充电区间（直到 54%–80% SOC 才切换），电池在负极锂离子扩散速率较高的低 SOC 区域接受了温和的电流。短寿策略则在极低 SOC（4%–10%）处即切换至高倍率，意味着电池在 SOC 尚未充分建立时就被迫承受大电流冲击，石墨负极表面更易发生锂金属沉积（析锂），形成不可逆的活性锂损失。

此外，长寿策略的 C_1 与 C_2 基本相等（如 3.6C→3.6C、4.8C→4.8C），充电过程中电流保持平稳。而短寿策略中最极端的 1C(4%)-6C 和 2C(10%)-6C，经历了 5C 级别的倍率跳变，这种瞬时切换会在电极/电解液界面产生剧烈的浓度梯度和应力，是诱发析锂和颗粒破裂的典型工况。

4 Spearman 秩相关与 SOC 区间分析

采用 Spearman 秩相关系数量化充电策略参数与循环寿命之间的单调关系。Spearman 相关系数 ρ 不假设线性关系，对异常值稳健，适合小样本（ $n = 124$ ）下的相关性推断。 $\rho \in [-1, +1]$ ， $p < 0.05$ 判定为显著。

4.1 单一参数主效应

表5给出了三个核心策略参数与循环寿命的 Spearman 相关结果。

表 5: 单一参数 vs 循环寿命的 Spearman 相关

参数	Spearman ρ	p -value	FDR 校正
C_1 (第一步倍率)	+0.110	0.224	不显著
Q_1 (切换 SOC)	+0.318	3.2×10^{-4}	显著
C_2 (第二步倍率)	-0.288	1.2×10^{-3}	显著
平均充电时间	-0.528	2.9×10^{-10}	显著 (最强)
$ C_1 - C_2 $ 倍率跳变	-0.213	0.018	显著


结果表明： Q_1 是最关键的可解释策略参数 ($\rho = +0.318$, FDR 显著)；更高的 Q_1 意味着电池在低 SOC 区间停留更长时间后才切换至第二步。平均充电时间是更强的主效应 ($\rho = -0.528$)，但需注意它与“低倍率 $\rightarrow$ 慢充 $\rightarrow$ 长寿”部分同义。 C_2 的影响为负 ($\rho = -0.288$)； C_1 单独不显著 (FDR $p = 0.26$)，说明损害来源于 C_1 与 C_2 的搭配方式而非 C_1 本身。

4.2 不同 SOC 区间的倍率效应

将 SOC 0–100% 划分为 5 个区间，推导每个电池在各区间的等效 C-rate 暴露量，分别与循环寿命做 Spearman 相关。结果如表6和图2所示。

表 6: 各 SOC 区间 C-rate 暴露量与循环寿命的 Spearman 相关


SOC 区间	Spearman ρ	p -value	显著性
0–20%	+0.085	0.348	不显著
20–40%	-0.168	0.063	不显著
40–60%	-0.287	1.2×10^{-3}	显著
60–80%	-0.330	1.8×10^{-4}	显著
80–100%	N/A	N/A	常数 (均为 1C CC-CV)

图 2: 各 SOC 区间 C-rate 暴露量与循环寿命的 Spearman ρ 柱状图

核心发现: 损害梯度随 SOC 单调递增——低 SOC 区间 (0-20%) 的 C-rate 与寿命无显著相关 ($\rho \approx 0$), SOC 40-80% 是“危险区间”, 该区间内高倍率充电对电池造成不可逆损害。物理机制上, 高 SOC 下石墨负极嵌锂接近饱和, 锂离子扩散速率显著下降, 大倍率电流将导致负极表面锂金属沉积 (析锂)、SEI 膜加速增厚和电极颗粒微裂纹。

4.3 散点图验证

图3展示了 C_1 、 Q_1 、 C_2 与循环寿命的散点图及 LOWESS 平滑趋势线。 Q_1 呈明显正趋势, C_2 呈明显负趋势, C_1 无明显趋势——与 Spearman ρ 结果完全一致。

图 3: C_1 、 Q_1 、 C_2 与循环寿命的散点图 (红色曲线为 LOWESS 非参数平滑趋势)

5 交互效应

5.1 分层 Spearman 交互分析

为量化因素间的交互作用，采用**分层 Spearman 分析**：按某一因素的中位数将电池分为高/低两组，比较另一因素在两组内的 Spearman ρ 差异。交互强度定义为：

$$\text{交互强度} = |\Delta\rho| = |\rho_{\text{高组}} - \rho_{\text{低组}}| \quad (2)$$

并用 **Fisher r-to-z 检验**判断两组 ρ 是否显著不同（而非仅凭 $|\Delta\rho|$ 大小下结论），全部检验统一做 Benjamini-Hochberg FDR 校正。表7汇总结果。

表 7: 分层 Spearman 交互效应分析（Fisher z 检验 + FDR 校正）

交互对	高组内 ρ	低组内 ρ	$ \Delta\rho $	p-value	显著
$C_1 \times Q_1$	高 C_1 : -0.212	低 C_1 : +0.612	0.824	4.8×10^{-7}	显著
$Q_1 \times C_2$	高 Q_1 : -0.013	低 Q_1 : -0.482	0.468	0.0054	显著
$ C_1 - C_2 \times Q_1$	大跳变: +0.166	小跳变: +0.487	0.320	0.054	不显著
$Q_1 \times \text{充电时间}$	长充电: +0.314	短充电: +0.107	0.207	0.24	不显著

5.2 交互效应的物理含义

$C_1 \times Q_1$ ($|\Delta\rho| = 0.824$, $p \approx 5 \times 10^{-7}$): 高 Q_1 延长寿命的效果仅存在于低 C_1 条件下 ($\rho = +0.612$)。当 C_1 较高时，提高 Q_1 反而呈微弱负相关 ($\rho = -0.212$)。换言之——如果第一步已经用高倍率充电，延迟切换 SOC 并不能挽救电池，高 C_1 本身的损伤已经不可逆。

$Q_1 \times C_2$ ($|\Delta\rho| = 0.468$, $p \approx 0.005$): C_2 的损害作用仅存在于低 Q_1 条件下 ($\rho = -0.482$)。当 Q_1 较高时， C_2 与寿命几乎无关 ($\rho = -0.013$)，因为高 Q_1 意味着电池在进入高 SOC 危险区之前已完成大部分充电——高 Q_1 充当了“保护伞”。

> 注：其余两个候选交互 ($|C_1 - C_2| \times Q_1$ 、 $Q_1 \times \text{充电时间}$) 的 $|\Delta\rho|$ 虽不为零，但 Fisher z 检验未达显著，不据此下结论。

5.3 主效应与交互效应分列

主效应 ($|\rho|$) 与交互 ($|\Delta\rho|$) 是不同含义的统计量，本报告不再把二者相加进同一张排序表，而是分列呈现（见图4，均附 FDR 显著性标记）。经 Fisher z 检验，两个交互效应显著 ($C_1 \times Q_1$ 、 $Q_1 \times C_2$)，且都涉及 Q_1 —— Q_1 不仅是显著的主效应，更是显著交互效应的枢纽变量。




图 4: 各因素及交互作用对循环寿命的影响程度排序

6 基于 Transformer 的寿命预测

6.1 问题定义

给定电池前 $T = 100$ 个循环的测量数据，预测其总循环寿命（early cycle-life prediction）。形式化为时序回归问题：

$$\hat{y} = f(\mathbf{X}_{1:T}), \quad \mathbf{X}_t \in \mathbb{R}^D \quad (3)$$

其中 $\hat{y}$ 为预测循环寿命， D 为每循环特征维度。

6.2 四层渐进式特征体系

设计四层特征体系，逐层增加物理信息量：

- **A —基础退化信号（6 维）**：SOH、IR、温度 (Tavg)、充电容量 (QCharge)、放电容量 (QDischarge)、充电时间，每循环标量；
- **B —快充策略参数（+3 维）**： C_1 、 Q_1 、 C_2 ，每电池静态参数，循环间重复；
- **C —SOC 区间倍率暴露（+4 维）**：由 (C_1, Q_1, C_2) 推导的 4 个 SOC 区间（0–20%，20–40%，40–60%，60–80%）等效 C-rate；
- **D —dQ/dV 曲线统计量（+5 维）**：每循环从微分容量曲线提取的方差、峰数量、主峰高度、主峰位置、偏度。受 Severson et al.[1] 启发，但仅使用标量统计量而非原始曲线以避免过拟合。

6.3 Transformer 模型架构

采用标准的 Transformer 编码器架构进行时序回归，结构如图5所示：




图 5: Transformer 预测模型架构

训练配置：Adam 优化器 ($lr=1 \times 10^{-3}$, $weight_decay=1 \times 10^{-4}$)，ReduceLROnPlateau 学习率调度，MSE 损失函数，200 个 epoch，batch_size=16，梯度裁剪阈值 1.0。

6.4 实验设计

- **模型对比 (Phase 1, 公平对比)**：固定 Feature B (9 维)，比较 Ridge 回归、随机森林 ($n=200$, $max_depth=8$)、LSTM (2 层, $hidden=64$) 和 Transformer (2 层, $d_model=64$)。Ridge/RF 与 LSTM/Transformer 输入同一套前 100 循环原始特征——Ridge/RF 用展平的 ($100 \times 9 = 900$) 维向量，LSTM/Transformer 用 (100×9) 时序，避免信息量不对等。5 折交叉验证，固定 seed。
- **特征消融 (Phase 2)**：固定 Transformer，逐层叠加 $A \rightarrow B \rightarrow C \rightarrow D$ 。5 折交叉验证，多个 seed，逐层对比用配对 Wilcoxon 检验判断 R^2 增量是否显著。
- **留出测试集 (Phase 3)**：按 cycle_life 分位数分层，约 80/10/10 (train/val/test)，重复 10 次不同划分，报告 Test R^2 /MAE/RMSE 的均值 $\pm$ 标准差。

6.5 软件环境

Python 3.12, torch $\geq$ 2.0 (实测 2.11, CUDA 12.8), scikit-learn, scipy, h5py。训练在 NVIDIA RTX 5070 GPU 上完成。

7 预测结果与分析

7.1 模型对比

表8给出了四类模型在 5 折交叉验证下的预测性能对比。

表 8: 模型对比结果 (5 折交叉验证, Feature B)

模型	MAE	RMSE	R ²	MAPE
Dummy(预测均值)	283±18	380±70	−0.076±0.096	41.5%
Ridge (展平序列 900 维)	178±31	236±50	0.577±0.097	23.6%
随机森林 (展平序列 900 维)	157±26	237±44	0.560±0.163	20.4%
LSTM	116±32	154±36	0.798±0.137	15.8%
Transformer	109±23	145±29	0.834±0.067	14.5%

在公平对比 (所有模型输入同一套前 100 循环原始序列, 序列模型跨 5 个 seed) 下, Ridge 达到 R²=0.577——说明原先 “Ridge R² = −0.09” 是让线性模型吃手工聚合特征所致的不公平对比, 而非线性模型本身失败。Transformer 最优 (R²=0.834, 5 个 seed 高度一致), 但优势幅度 (相对 Ridge 约 +0.26) 比此前宣称的要温和。朴素基线 (预测均值) R² $\approx$ 0、MAPE 41.5%, 说明模型确实学到退化信号而非仅靠均值。

7.2 特征消融实验

表9和图6展示了逐层叠加特征的 R² 变化。

表 9: 特征消融实验结果 (Transformer, 5 折交叉验证)

特征层	维度	R ²	ΔR^2 (中位)	Wilcoxon p	结论
A (基础退化)	6	0.730±0.108	—	—	基线
B (+ 策略参数)	9	0.835±0.068	+0.103	1.5×10^{-6}	显著
C (+SOC 暴露)	13	0.859±0.028	+0.007	0.12	不显著
D (+dQ/dV)	18	0.880±0.067	+0.032	0.080	不显著




图 6: 特征消融实验：逐层特征叠加的 R² 提升

用配对 Wilcoxon 检验（对同一 (seed, fold) 的 R² 逐对比较）后，只有策略参数 (B) 带来显著增益 (ΔR² 中位 +0.103, $p \approx 1.5 \times 10^{-6}$)。SOC 区间倍率暴露 (C) 无显著增益 ($p = 0.12$)——这与它们由 C1/Q1/C2 确定性推导、高度共线的判断一致，印证“40–80% 危险区间”与“Q1 重要”部分是同一条信息的两种表述。dQ/dV (D) 为边缘 ($p = 0.080$)，不足以宣称确定增益。

7.3 留出测试集性能

按 cycle_life 分位数分层，重复 10 次划分（每次约 10 颗测试电池），最终测试结果如表10和图7所示。

表 10: 留出测试集性能（10 次分层划分均值 ± 标准差）

指标	数值
Test MAE	130±31 cycles
Test RMSE	176±56 cycles
Test R ²	0.773±0.175
Test MAPE	18.8±7.2%




图 7: 预测 vs 真实循环寿命散点图（5 折交叉验证汇总）

10 次分层留出的 R^2 均值 0.773，标准差 0.175——说明单次划分的 R^2 置信区间很宽，不足以支撑“显著优于”的结论。模型对未见电池有中等泛化能力，但受测试集划分影响较大。

7.4 与已发表基线的定位

表 11: 本文与已发表方法的预测误差对比（同一数据集）

方法	数据	测试误差 (MAPE)
Severson et al. 2019（Full 模型，前 100 循环）[1]	同数据集 124 颗 LFP	约 9.1%（Full 模型约 7.5%）
本文（Transformer，留出测试集）	同数据集	18.8±7.2%

本文在同一数据集上的留出测试 MAPE（18.8%）约为 Severson 2019 已发表方法（9.1%）的 2 倍。因此本文的贡献在于方法流程与可解释性（公平对比、显著性检验、落在主模型上的归因），而不在预测精度上领先——论文措辞据此降级，不再自称“高精度模型”。

8 可解释性分析

8.1 Transformer 可解释性（Integrated Gradients 与置换重要性）

对产生预测结论的模型本身——Transformer（Feature D, 18 维）——做归因分析，而非在另一个随机森林代理模型上计算 SHAP。采用两类方法：Integrated Gradients（IG）对输入（100×18）逐时间步 × 特征归因，置换重要性逐特征打乱测量测试集 R² 下降。





图 8: Transformer Integrated Gradients 特征重要性 (对测试集平均)

图 9: Transformer 置换重要性 (打乱该特征后测试 R^2 下降越多越重要)

IG 归因最强的动态特征是内阻 (IR); SOC 区间倍率 (Crate_*) 与策略参数 (C1/C2) 在 IG 与置换重要性中排名靠前。注意: 置换重要性高反映模型“依赖”该特征, 并不等价于对泛化有益——消融已显示 SOC 区间特征无 R^2 增益 (与 C1/Q1/C2 共线)。故以 IG 与消融一致的特征 (IR、策略参数) 作为主结论; 置换重要性采用固定 seed 多次打乱取均值以降低方差。逐特征归因值见 `results/metrics.json`。

8.2 注意力 rollout 与基线对照

为避免对注意力的过度解读, 采用注意力 rollout (逐层头平均 + 残差连乘) 并加入两个基线: 随机初始化模型的 rollout、以及时间轴打乱对照。




图 10: 注意力 rollout 对比（训练模型 vs 随机初始化基线）




图 11: rollout 时间步贡献分布：最终预测依赖历史哪些步

训练模型的 rollout 模式与随机初始化基线明显不同，说明注意力学到了非平凡结构。**时间轴打乱对照：**打乱 100 个时间步后重训，测试 R^2 从 0.853 降至 0.846（仅下降 0.007），说明模型几乎完全依赖退化“水平”信息（SOH/IR 当前值）而非严格的时间顺序——因此不宜解读为“Transformer 捕捉长程时序依赖”，其优势主要来自对多变量水平的非线性组合。

9 讨论

9.1 研究闭环验证

本研究构建了统计分析 → 机器学习 → 可解释验证的完整研究闭环：

Spearman + Fisher z 统计 → Q_1, C_2 , SOC 40–80% 显著; $C_1 \times Q_1, Q_1 \times C_2$ 交互显著

↓

Transformer 预测 → 策略参数与 dQ/dV 有正向增量 (SOC 区间特征无增益)

↓

IG/置换/rollout 可解释 → IR、充电时间、 Q_1 排名靠前

↓

物理机制 → 高 SOC 倍率 → 析锂 + SEI 增长 + 颗粒破裂

三层面分析结果高度一致：统计层面发现 Q_1, C_2 和 SOC 区间倍率是关键变量，预测层面特征消融验证了策略参数与 dQ/dV 的增量贡献（并揭示 SOC 区间特征无增益），可解释层面确认了相同特征在模型决策中的重要性。

9.2 与数据一致的设计方向

基于以上分析，提出与数据一致的设计方向（注意：以下为观测相关性，非因果结论）：

- (1) **SOC 0–40% 区间集中高倍率充电**：该区间负极锂离子扩散快、析锂风险小，可安全承受较大电流；
- (2) **SOC 40–80% 区间降低倍率**：该区间为“危险区间”，高倍率充电与较短寿命相关。Spearman 分析表明该区间 C-rate 与寿命负相关性最强 ($\rho = -0.330$)；
- (3) **保持两步倍率平滑过渡**：避免 C_1 与 C_2 之间的大幅跳变 ($> 1.5C$)，以减少电极/电解液界面的浓度梯度冲击；
- (4) **在低 C_1 前提下提高 Q_1** ： $C_1 \times Q_1$ 交互效应 ($|\Delta\rho| = 0.824$, Fisher z 检验 $p \approx 5 \times 10^{-7}$) 表明，高 Q_1 的保护效应仅存在于低 C_1 条件下。

9.3 研究局限

- (1) **样本不均衡**：短寿策略各仅有 1 颗电池，统计代表性有限。Top 5 短寿策略的结论需更多独立重复实验验证；
- (2) **批次混杂与敏感性检验**：SOC 区间倍率暴露是 (C_1, Q_1, C_2) 的确定性函数，各区间的 ρ 是同一组变量的再编码，并非独立证据。本数据集的 `channel_id/barcode` 字段在 cleaned 版本中已被清空（全为 0xDD000000 删除标记），无法直接按批次控制；仅能用 policy 的 `-newstructure` 后缀做粗略 2 组代理。**批内敏感性检验**： Q_1 与寿命的相关在两组内均稳健（newstructure 组 $\rho = 0.448$ ，无后缀组

$\rho = 0.353$, 均与总体 $\rho = 0.318$ 同向且显著), 说明 Q_1 的效应不太可能纯粹来自这一批次代理, 但仍不能排除其他未观测批次混杂, 故不作因果解读;

- (3) **单一电池化学**: 数据集仅包含 A123 LFP/石墨体系, 结论向 NMC、NCA 等其他化学体系的推广需谨慎;
- (4) **实验室条件**: 所有电池在恒温条件下测试, 未考虑实际使用中的温度波动、部分充放电等复杂工况;
- (5) **特征维度有限**: 仅使用前 100 个循环的特征, 更长的早期观测窗口可能进一步提升预测精度。

10 结论

本文基于 MIT-Stanford 124 颗 A123 LFP 18650 电池的快充老化数据集, 完成了从统计分析到机器学习预测再到可解释性验证的系统研究。主要结论如下:

- (1) Q_1 (阶段切换 SOC) 是最关键的可解释策略参数。Spearman $\rho = +0.318$ (FDR 显著), 且是经 Fisher z 检验显著的交互效应 ($C_1 \times Q_1$ 、 $Q_1 \times C_2$) 的枢纽变量;
- (2) SOC 40–80% 是高倍率充电的“危险区间”。该区间 C-rate 暴露量与循环寿命的 Spearman ρ 达 -0.330 ($p < 0.001$), 而 SOC 0–20% 几乎无影响 ($\rho = +0.085, n.s.$);
- (3) 交互效应经检验而非仅凭强度排序。Fisher r-to-z 检验确认 $C_1 \times Q_1$ ($|\Delta\rho| = 0.824$) 与 $Q_1 \times C_2$ ($|\Delta\rho| = 0.468$) 显著, 其余候选交互不显著——最优策略是在低 C_1 + 高 Q_1 + $C_1 \approx C_2$ 的组合下实现协同保护;
- (4) **Transformer** 在公平对比下表现最优, 但精度不领先于已发表方法。四层渐进式特征体系下, 5 折交叉验证 R^2 达 0.834 (Ridge 公平对比 0.577), 留出测试集 (10 次分层划分) R^2 为 0.773 ± 0.175 、MAPE 18.8% (约为 Severson 2019 的 2 倍);
- (5) **IG/置换/rollout** 分析落在主模型本身。IG 归因最强的动态特征是内阻 (IR), SOC 区间倍率与策略参数 (C_1/C_2) 排名靠前; 时间轴打乱对照提示模型主要依赖退化水平信息而非严格时序顺序。

本研究提供了流程完整的电池寿命预测方法, 更重要的是通过多维度的统计分析揭示了快充策略参数之间的复杂交互机制, 为快充协议的设计提供了与数据一致的物理指导; 其贡献在于方法流程与可解释性, 而非在预测精度上领先于已发表基线。

参考文献

- [1] Severson, K. A., Attia, P. M., Jin, N., et al. Data-driven prediction of battery cycle life before capacity degradation. *Nature Energy*, 2019, 4: 383–391.
- [2] Lundberg, S. M., Lee, S. I. A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems (NeurIPS)*, 2017, 30: 4765–4774.
- [3] Vaswani, A., Shazeer, N., Parmar, N., et al. Attention is all you need. *Advances in Neural Information Processing Systems (NeurIPS)*, 2017, 30: 5998–6008.
- [4] Attia, P. M., Severson, K. A., Witmer, J. D. Statistical learning for accurate and interpretable battery lifetime prediction. *Journal of the Electrochemical Society*, 2022, 169(6): 060517.
- [5] Edge, J. S., O’Kane, S., Prosser, J., et al. Lithium ion battery degradation: what you need to know. *Physical Chemistry Chemical Physics*, 2021, 23(14): 8200–8221.
- [6] Liu, K., Li, K., Peng, Q., Zhang, C. A brief review on key technologies in the battery management system of electric vehicles. *Frontiers of Mechanical Engineering*, 2020, 15: 47–64.

A 特征列表

表12汇总了 Feature D 全部 18 维特征的定义和来源。

表 12: Feature D 全部 18 维特征定义

序号	特征名	来源
1	SOH	放电容量 / 1.1Ah
2	IR	内阻测量 (每循环)
3	Tavg	平均温度 (每循环)
4	QCharge	充电容量 (每循环)
5	QDischarge	放电容量 (每循环)
6	chargetime	充电时间 (每循环)
7	C_1	第一步充电倍率 (静态)
8	Q_1	阶段切换 SOC (静态)
9	C_2	第二步充电倍率 (静态)
10	Crate_0-20	SOC 0-20% 等效 C-rate
11	Crate_20-40	SOC 20-40% 等效 C-rate
12	Crate_40-60	SOC 40-60% 等效 C-rate
13	Crate_60-80	SOC 60-80% 等效 C-rate
14	dQdV_var	dQ/dV 曲线方差
15	dQdV_nPeaks	dQ/dV 峰数量
16	dQdV_peakH	主峰高度
17	dQdV_peakPos	主峰位置 (归一化)
18	dQdV_skew	dQ/dV 曲线偏度